

Utilisation et exploitation des Grands Modèles de Langage (LLMs) pour une Analyse Multimodale des états émotionnels.

Contexte et état de l’art scientifique

L’analyse multimodale des émotions (AME) vise à combiner plusieurs modalités (texte, image, audio, vidéo) pour mieux interpréter les états émotionnels exprimés dans un contenu sémantique (texte). Toutefois, la majorité des expressions émotionnelles provient souvent du **texte**, notamment des textes présents sur Internet, les réseaux sociaux, dans les avis d’utilisateurs, etc.

Les approches classiques basées sur des fusions simples (early/late fusion) souffrent de limitations comme le **désalignement modal**, la **fusion sous-optimale**, et une **sensibilité accrue au bruit intermodal**. Les modèles récents à base de *Transformers multimodaux* (MMBT, LXMERT, VisualBERT) ont permis des avancées notables, mais restent complexes et peu flexibles.

Avec l’émergence de **Grands Modèles de Langage multimodaux** (ex : Flamingo, LLaVA, GPT-4V), il devient possible de *centrer l’analyse sur le texte* tout en exploitant d’autres modalités (visuelle, audio) comme renforts sémantiques. Ces modèles permettent un **raisonnement croisé modalité/texte** plus fluide et contrôlable et ouvrent de nouvelles perspectives dans l’analyse plus fine et plus pertinente d’expressions émotionnelles et de dissonance entre les opinions textuelles et les états émotionnels de l’individu.

Objectifs du stage de recherche

Objectifs pour la période avant le stage

- Faire l’état de l’art des recherches menées sur l’utilisation des LLMs dans la détection des incohérences émotionnelles entre les données sémantiques (textes) et les données exprimées par l’utilisateur (vidéo, audio, images, etc.) [?].
- Il s’agira de démontrer qu’il est possible de détecter des incohérences entre le contenu émotionnel du texte (sémantique) et les réactions émotionnelles (vidéo, audio, etc.) des individus s’exprimant par écrit.

Objectifs

- Proposer une architecture LLM-compatible pour l’analyse des états émotionnels avec des sources/données multimodales mais centrées sur le texte.
- Comparer les différentes stratégies de fusion : prompting multimodal, adaptation légère (LoRA, MLP adapters) ou encodage croisé.
- Étudier la robustesse face au **bruit visuel ou audio** et à l’ambiguïté textuelle (ex : ironie, sarcasme).
- Évaluer les performances sur des benchmarks publics.

Bases de données

- **CMU-MOSEI** : vidéos annotées avec émotions et opinions (texte + audio + vidéo).
- **MELD** : dialogues multimodaux extraits de la série *Friends*.
- **MVSA** : tweets avec image et texte annotés par opinion.
- **CH-SIMS** : corpus chinois avec attention intermodal explicite.

Technologies et outils

- **Langages** : Python, PyTorch, Transformers (HuggingFace)
- **Modèles** : LLaVA, BLIP-2, OpenFlamingo, GPT-4V (via API)
- **Métriques** : F1, MAE, Pearson, accuracy émotion/sentiment

Références bibliographiques

- Yang et al., *Large Language Models Meet Text-Centric Multimodal Sentiment Analysis : A Survey*, arXiv, 2024. <https://arxiv.org/abs/2406.08068>
- Yang et al., *Data Uncertainty-Aware Learning for Multimodal Aspect-based Sentiment Analysis*, arXiv, 2024. <https://arxiv.org/abs/2412.01249>
- Tsai et al., *Multimodal Transformer for Multimodal Sentiment Analysis*, ACL, 2019. <https://aclanthology.org/P19-1656/>

Définition des mots clés

- **Désalignement modal** : Cela désigne une mauvaise correspondance entre les différentes modalités (par exemple, image et texte). Si une image montre un objet et que le texte parle d'autre chose, ou que les deux ne sont pas synchronisés, cela crée un désalignement qui nuit à la compréhension globale.
- **Fusion sous-optimale** : Dans les approches de fusion (comme early fusion ou late fusion), les informations issues de différentes modalités ne sont pas toujours combinées de manière efficace. Cela peut conduire à une intégration pauvre, où l'on ne profite pas pleinement des complémentarités entre texte, image, son, etc.
- **Sensibilité accrue au bruit intermodal** : Cela signifie que ces modèles sont plus vulnérables aux incohérences ou au "bruit" entre les modalités. Par exemple, si une modalité contient une information incorrecte ou ambiguë (comme une image floue ou un texte peu clair), cela peut fortement dégrader la performance du système.
- **Grands Modèles de Langage multimodaux** : Ce sont des modèles d'IA puissants capables de traiter plusieurs types de données (texte, image, etc.) en même temps. Exemples : Flamingo, LLaVA, GPT-4V. Ils intègrent toutes les modalités dans une seule architecture cohérente.
- **Raisonnement croisé modalité/texte** : Cela fait référence à la capacité du modèle à comprendre et raisonner en combinant différentes modalités (par exemple, en reliant ce qui est vu dans une image à ce qui est dit dans un texte), pour produire une interprétation plus riche et plus précise.

Information sur les données à traiter

- **CMU-MOSEI** : Contient plus de 23 000 segments vidéo issus de YouTube, chacun annoté avec des informations textuelles, audio et visuelles. Les labels incluent :
 - *Score de sentiment* (de -3 à +3, où -3 est très négatif et +3 très positif),
 - *Émotions discrètes* (joie, tristesse, colère, peur, etc.).
- **MELD (Multimodal EmotionLines Dataset)** : Dialogues multimodaux extraits de la série *Friends*. Chaque segment est annoté avec :
 - *Émotions* (joie, colère, surprise, tristesse, peur, dégoût, neutre),
 - *Sentiment global* (positif, négatif, neutre).
- **MVSA (Multimodal Visual Sentiment Analysis)** : Tweets multimodaux (texte + image) annotés manuellement. Chaque exemple est labellisé par :
 - *Polarité de sentiment* (positif, neutre, négatif).
- **CH-SIMS** : Corpus chinois pour l'analyse multimodale de sentiments implicites. Il inclut des annotations :
 - *De sentiment explicite et implicite* (positif, neutre, négatif),
 - *Avec attention intermodale annotée manuellement*, reliant les modalités pertinentes (texte, audio, vidéo) pour chaque segment.